

# Predicción de defectos en proyectos de software utilizando técnicas de minería de datos y aprendizaje computacional sobre datasets de Jira

Emmanuel Gracida Tapia<sup>1</sup>[0000-1111-2222-3333], Angel Luis Valdés  
Sánchez<sup>1</sup>[0009-0003-4694-9780], Bernardino Hernández  
Rojas<sup>1</sup>[2222--3333-4444-5555], and Octavio Paz<sup>1</sup>[2222--3333-4444-5555]

Universidad Tecnológica de la Mixteca, CP 69004, Huajuapán de León, Oaxaca

**Resumen** La predicción de errores en el software es una tarea esencial para mejorar la calidad y confiabilidad de los sistemas antes de su implementación. En este trabajo se aplican técnicas de minería de datos y aprendizaje computacional sobre datasets provenientes de proyectos reales del repositorio Jira (Apache ActiveMQ, Derby, Hive y Wicket), con el objetivo de identificar módulos propensos a fallas. Se emplean diversos métodos de preprocesamiento, como la limpieza de datos, normalización, balanceo de clases y selección de características, seguidos por la aplicación de modelos de clasificación supervisada. Los resultados obtenidos permitirán analizar la efectividad de diferentes enfoques predictivos y su capacidad para contribuir a la detección temprana de defectos en proyectos de software.

**Keywords:** Predicción de errores · minería de datos · aprendizaje computacional · métricas del software · calidad del software · Jira · clasificación.

## 1. Introducción

La predicción de errores de software es una tarea fundamental dentro de la Ingeniería de Software, ya que permite identificar módulos o componentes propensos a fallas antes de su despliegue. Este proceso contribuye a mejorar la calidad del producto y optimizar los recursos dedicados a pruebas y mantenimiento. En este trabajo se realiza un estudio aplicado de técnicas de minería de datos y aprendizaje automático sobre un conjunto de datasets provenientes del repositorio Jira, que recopila información de proyectos de software reales como ActiveMQ, Derby, Hive y Wicket. El objetivo es aplicar técnicas de preprocesamiento, selección de características y modelos predictivos para estimar la probabilidad de defectos en el código, evaluando el rendimiento de los algoritmos empleados mediante métricas comunes en la predicción de fallas.

## 2. Materiales

Para el desarrollo de este trabajo se utilizaron conjuntos de datos públicos obtenidos de proyectos del repositorio *Jira*, los cuales pertenecen a sistemas de

software reales del ecosistema Apache. Cada conjunto de datos contiene métricas extraídas de versiones específicas del software, incluyendo información sobre la complejidad del código, número de líneas, cantidad de métodos, historial de cambios y la presencia o ausencia de defectos reportados.

Los datasets empleados fueron los siguientes:

- **activemq-5.0.0.csv**: datos correspondientes a la versión 5.0.0 del sistema de mensajería Apache ActiveMQ.
- **derby-10.5.11.csv**: perteneciente al sistema de base de datos embebida Apache Derby.
- **hive-0.90.csv**: proveniente del sistema de almacenamiento y análisis de datos Apache Hive.
- **wicket-1.3.0-beta2.csv**: basado en el framework web Apache Wicket.

Cada uno de estos conjuntos de datos representa módulos o clases del software, acompañados de una etiqueta binaria que indica si el componente fue defectuoso o no. Esto permite abordar el problema como una tarea de clasificación supervisada orientada a la predicción de defectos de software.


### 3. Métodos

El proceso metodológico seguido en este trabajo se basa en las etapas clásicas de la minería de datos y el aprendizaje computacional. En primer lugar, se llevará a cabo el preprocesamiento de los datos, el cual incluye diversas tareas esenciales para garantizar la calidad y consistencia de la información utilizada. Entre estas tareas se contemplan la imputación de valores faltantes, la normalización de atributos numéricos, la eliminación de valores atípicos y el balanceo de clases mediante técnicas como *SMOTE* (*Synthetic Minority Over-sampling Technique*).

Posteriormente, se realizará una selección de características con el fin de identificar los atributos más relevantes para la predicción de defectos, reduciendo la dimensionalidad y mejorando el rendimiento de los modelos. Una vez preparado el conjunto de datos, se procederá a la fase de modelado, en la que se aplicará un algoritmo de clasificación supervisada, como los árboles de decisión.

Finalmente, los modelos serán evaluados utilizando métricas de desempeño como la precisión, el *recall* y el puntaje F1, con el propósito de comparar la efectividad de cada enfoque predictivo.

En la se presenta una figura que muestra el flujo general del proceso de preprocesamiento, detallando las etapas y transformaciones aplicadas a los datos antes del modelado.



**Figura 1.** Flujo general del proceso de preprocesamiento de datos.

#### 4. Resultados

#### 5. Conclusión

#### 6. Referencias