

Predicción de errores en Ingeniería de Software

Clasificación

Raúl Cruz Barbosa

Instituto de Computación

Universidad Tecnológica de la Mixteca



- 1 Clasificación para predicción de errores
 - Introducción
 - Bayes Decision Theory
 - Clasificador Bayesiano
 - Clasificador de Bayes Ingenuo
 - Árboles de Decisión
 - Máquinas de Soporte Vectorial (SVM)

Outline

- 1 Clasificación para predicción de errores
 - Introducción
 - Bayes Decision Theory
 - Clasificador Bayesiano
 - Clasificador de Bayes Ingenuo
 - Árboles de Decisión
 - Máquinas de Soporte Vectorial (SVM)

Introduction

Here our objective is to design classifiers based on **Bayes decision theory**. The approach to be followed is based on probabilistic arguments stemming from the **statistical** nature of the generated features. This is due to the statistical variation of the patterns as well as to the noise in the measuring sensors.

We will design classifiers that classify an unknown pattern in the most probable of the classes. Then, our task becomes that of defining what “**most probable**” means.

Given a classification task of M classes: $\omega_1, \omega_2, \dots, \omega_M$, and an unknown pattern, which is represented by a feature vector $\mathbf{x}$, we form the M conditional probabilities $P(\omega_i|\mathbf{x})$, $i = 1, 2, \dots, M$ (also referred to as *a posteriori probabilities*).

Introduction

In other words, each $P(\omega_j|\mathbf{x})$ represents the probability that the unknown pattern belongs to the respective class ω_j , given that the corresponding feature vector takes the value $\mathbf{x}$.

The classifiers to be considered now on compute either the maximum of these M values or, equivalently, the maximum of an appropriately defined function of them. The unknown pattern is then assigned to the class corresponding to this maximum.

In this sense, the first task we are face with is the computation of the **conditional probabilities**.

Outline

- 1 Clasificación para predicción de errores
 - Introducción
 - **Bayes Decision Theory**
 - Clasificador Bayesiano
 - Clasificador de Bayes Ingenuo
 - Árboles de Decisión
 - Máquinas de Soporte Vectorial (SVM)

Bayes Decision Theory

First, we will focus on the two-class case. Let ω_1, ω_2 be the two classes in which our patterns belong. Also, we assume that the *a priori probabilities* $P(\omega_1), P(\omega_2)$ are known (if not they can be estimated from the available training feature vectors).

The other statistical quantities assumed to be known are the class-conditional probability density functions $p(\mathbf{x}|\omega_i), i = 1, 2$, describing the distribution of the feature vectors in each of the classes. The pdf $p(\mathbf{x}|\omega_i)$ is also referred to as the likelihood function of ω_i with respect to $\mathbf{x}$.

It is also assumed that feature vectors can take any value in the l -dimensional feature space. In the case that feature vectors can take only discrete values, density functions $p(\mathbf{x}|\omega_i)$ become probabilities and will be denoted by $P(\mathbf{x}|\omega_i)$.

Bayes Decision Theory

We can now compute the previously mentioned conditional probabilities through the **Bayes rule**:

$$P(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{p(\mathbf{x})}$$

where $p(\mathbf{x})$ is the pdf of $\mathbf{x}$ which is computed as

$$p(\mathbf{x}) = \sum_{i=1}^2 p(\mathbf{x}|\omega_i)P(\omega_i)$$

The **Bayes classification rule** can be stated as

If $P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x})$, $\mathbf{x}$ is classified to ω_1

If $P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x})$, $\mathbf{x}$ is classified to ω_2

Bayes Decision Theory

The case of equality is detrimental and the pattern can be assigned to either of the two classes. Using the Bayes rule, the decision can equivalently be based on the inequalities

$$p(\mathbf{x}|\omega_1)P(\omega_1) \geq p(\mathbf{x}|\omega_2)P(\omega_2)$$

$p(\mathbf{x})$ is not taken into account, because it is the same for all classes and it does not affect the decision. If the *a priori* probabilities are equal ($P(\omega_1) = P(\omega_2) = 1/2$) then the decision is based on

$$p(\mathbf{x}|\omega_1) \geq p(\mathbf{x}|\omega_2)$$

Thus, the search for the maximum now rests on the values of the conditional pdfs evaluated at $\mathbf{x}$.

Outline

- 1 Clasificación para predicción de errores
 - Introducción
 - Bayes Decision Theory
 - **Clasificador Bayesiano**
 - Clasificador de Bayes Ingenuo
 - Árboles de Decisión
 - Máquinas de Soporte Vectorial (SVM)

Práctica: Clasificador Bayesiano

Dada la función de densidad de probabilidad Gaussiana, programarla para:

- El caso de una dimensión:

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- El caso de l -dimensiones:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{l/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)\right)$$

donde $\mu = E[\mathbf{x}]$ es el valor medio y Σ es la $l \times l$ **matriz de covarianza** definida como

$$\Sigma = E[(\mathbf{x} - \mu)(\mathbf{x} - \mu)^T]$$

donde $|\Sigma|$ denota el determinante de Σ .

Práctica: Clasificador Bayesiano

Aplique la regla de Bayes para construir el clasificador Bayesiano:

En una tarea de clasificación con M clases, $\omega_1, \omega_2, \dots, \omega_M$, un patrón desconocido, representado por el vector de características $\mathbf{x}$, se asigna a la clase ω_i si

$$P(\omega_i|\mathbf{x}) > P(\omega_j|\mathbf{x}) \quad \forall j \neq i$$

donde $P(\omega_i|\mathbf{x}) \approx p(\mathbf{x}|\omega_i)P(\omega_i)$.

Ahora, suponga que $p(\mathbf{x}|\omega_i)$ se modela a través de una pdf Gaussiana. Entonces, basta calcular la pdf para cada punto (en el conjunto de datos) a través de las i clases y asignar dicho punto a la clase que maximice el producto de dicha pdf con la *probabilidad a priori* de la clase correspondiente. Esto es,

$$clase(\mathbf{x}) = \arg \max_i \{p(\mathbf{x}|\omega_i)P(\omega_i)\}$$

Práctica: Clasificador Bayesiano

Ejercicio 1: Calcule el valor de una pdf Gaussiana, $\mathcal{N}(m, S)$, en $x_1 = [0.2, 1.3]^T$ y $x_2 = [2.2, -1.3]^T$, donde

$$m = [0, 1]^T, S = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Ejercicio 2: Considere una tarea de clasificación de dos clases en el espacio de dos-dimensiones, donde los datos en ambas clases, ω_1, ω_2 , están distribuidas de acuerdo a las distribuciones Gaussianas $\mathcal{N}(m_1, S_1)$ y $\mathcal{N}(m_2, S_2)$, respectivamente. Sean

$$m_1 = [1, 1]^T, m_2 = [3, 3]^T, S_1 = S_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Suponga que $P(\omega_1) = P(\omega_2) = 1/2$, clasificar $x = [1.8, 1.8]^T$ en ω_1 o ω_2 .

Práctica: Clasificador Bayesiano

Ejercicio 3: Repita el ejemplo anterior para $P(\omega_1) = 1/6$ y $P(\omega_2) = 5/6$, y para $P(\omega_1) = 5/6$ y $P(\omega_2) = 1/6$. ¿De qué depende el resultado de clasificación?

Outline

- 1 Clasificación para predicción de errores
 - Introducción
 - Bayes Decision Theory
 - Clasificador Bayesiano
 - **Clasificador de Bayes Ingenuo**
 - Árboles de Decisión
 - Máquinas de Soporte Vectorial (SVM)

Clasificador de Bayes Ingenuo (naïve)

En el clasificador de Bayes se asume que se cuenta con un número de muestras de entrenamiento, N , suficientemente grande, de tal forma que se pueda obtener un buen estimado de la pdf de cada clase. Esto significa que el número de datos requeridos se incrementa exponencialmente de acuerdo a la dimensión l del espacio de características.

En otras palabras, si N se considera como un buen número de datos de entrenamiento para obtener una estimación suficientemente exacta de una pdf en un espacio de una dimensión, entonces N^l puntos serían requeridos para un espacio l -dimensional!

Para aliviar esto, un enfoque ampliamente utilizado es asumir que las características individuales x_j , $j = 1, 2, \dots, l$ son independientes estadísticamente. Entonces, podemos escribir

Clasificador de Bayes Ingenuo (naïve)

$$p(\mathbf{x}|\omega_i) = \prod_{j=1}^I p(x_j|\omega_i), \quad i = 1, 2, \dots, M$$

Ahora, para estimar I pdf's de una dimensión, para cada una de las clases, IN datos serían suficientes con el fin de obtener una buena estimación. Esto, guía al **clasificador naïve-Bayes**, el cual asigna una muestra desconocida $\mathbf{x} = [x_1, \dots, x_I]^T$ a la clase

$$\omega_m = \underset{\omega_i}{arg \max} \prod_{j=1}^I p(x_j|\omega_i), \quad i = 1, 2, \dots, M$$

El clasificador naïve-Bayes puede ser muy robusto a violaciones de la suposición de independencia, y su rendimiento es bueno para muchos conjuntos de datos del mundo real.

Práctica: Clasificador de Bayes Ingenuo (naïve)

Use el conjunto de datos Iris y suponga que para cada clase las características son independientes estadísticamente. Esto es, cada una de estas sigue una distribución Gaussiana de una dimensión. Además, suponga que las clases son igualmente probables.

- Divida el conjunto de datos original en una partición de 80 % para entrenamiento y otra de 20 % para prueba (Test).
- Para cada una de las 4-dimensiones y para cada una de las tres clases, use el conjunto de entrenamiento para calcular el estimado de máxima verosimilitud de los valores media $m_{1j}, m_{2j}, m_{3j}, j = 1, \dots, 4$ y las varianzas $\sigma_{1j}^2, \sigma_{2j}^2, \sigma_{3j}^2, j = 1, \dots, 4$

Práctica: Clasificador de Bayes Ingenuo (naïve)

- Clasifique los puntos del conjunto de prueba usando el clasificador de Bayes ingenuo, donde para un $\mathbf{x}$ dado, $p(\mathbf{x}|\omega_i)$ se estima como

$$p(\mathbf{x}|\omega_i) = \prod_{j=1}^4 \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left(-\frac{(x_j - m_{ij})^2}{2\sigma_{ij}^2}\right), i = 1, 2, 3$$

donde x_j es el j -ésimo componente de $\mathbf{x}$. Calcule la probabilidad de error.