

MEAN-SHIFT

**MÉTODO NO SUPERVISADO DE CLUSTERING BASADO
EN DENSIDADES DE DATOS**

Presentan:

ANGEL LUIS VALDES SANCHEZ
BERNARDINO HERNÁNDEZ ROJAS

¿QUÉ BUSCA ESTE ALGORITMO?

Busca automáticamente los picos de densidad en un conjunto de datos.

**En lugar de decirle cuántos clústeres se quieren,
Mean Shift deja que los datos hablen:
los puntos se van moviendo hacia las regiones donde
hay más puntos alrededor (más densidad).**








Imagen tomada de:

Comaniciu, D., & Meer, P. (2002). Mean shift: A robust approach toward feature space analysis. IEEE Transactions on Pattern Analysis and Machine Intelligence, 24(5), 603–619. <https://doi.org/10.1109/34.1000236>

**Al final, los puntos que se juntan en la misma región o
“pico” forman un clúster.**





ALGORITMO

Entrada:

- Conjunto de datos $X = \{x_1, x_2, \dots, x_n\}$ con n observaciones y d características
- Parámetro de ancho de banda $h > 0$
- Función kernel $K(x)$ (por ejemplo, Gaussiano o Epanechnikov)
- Umbral de convergencia $\varepsilon > 0$
- Umbral de fusión de modos $\tau > 0$

Salida:

- Conjunto de modos o centros de clústeres $\{\mu_1, \mu_2, \dots, \mu_k\}$
- Asignación de cada punto x_i a su clúster correspondiente

1. Inicialización:

Para cada punto de datos $x_i \in X$, establecer la posición inicial:

$$y_i^{(0)} = x_i$$

2. Iteración para cada punto y_i :

Repetir:

a. Identificar todos los puntos vecinos x_j tales que

$$\|x_j - y_i^{(t)}\| \leq h$$

b. Calcular la **media ponderada** de los vecinos utilizando el kernel:

$$y_i^{(t+1)} = \frac{\sum_{j=1}^n K\left(\frac{\|y_i^{(t)} - x_j\|^2}{h^2}\right) x_j}{\sum_{j=1}^n K\left(\frac{\|y_i^{(t)} - x_j\|^2}{h^2}\right)}$$

c. Calcular el **vector de desplazamiento (mean shift)**:

$$m(y_i^{(t)}) = y_i^{(t+1)} - y_i^{(t)}$$

d. Verificar la convergencia:

Si $\|m(y_i^{(t)})\| < \varepsilon$, detener la iteración para este punto;

de lo contrario, actualizar $y_i^{(t)} = y_i^{(t+1)}$ y repetir.

3. Obtención de modos:

Una vez que todos los puntos han convergido, almacenar los valores finales y_i como **modos candidatos**.

4. Fusión de modos cercanos:

Si dos modos y_i y y_j satisfacen

$$\|y_i - y_j\| < \tau,$$

fusionarlos en un único centro de clúster.

5. Asignación de clústeres:

Asignar cada punto original x_i al modo μ_j más cercano (el centro al que haya convergido).

1. Inicialización:

Para cada punto de datos $x_i \in X$, establecer la posición inicial:
 $y_i^{(0)} = x_i$

$X = \{x_1, x_2, \dots, x_{150}\}, \quad x_i \in \mathbb{R}^4$

Si $x_1 = (5.1, 3.5, 1.4, 0.2)$, entonces $y_1^{(0)} = (5.1, 3.5, 1.4, 0.2)$

Si $x_2 = (4.9, 3.0, 1.4, 0.2)$, entonces $y_2^{(0)} = (4.9, 3.0, 1.4, 0.2)$

... Y así sucesivamente hasta x_{150}

Atributo	Descripción
sepal_length	Longitud del sépalo (cm)
sepal_width	Ancho del sépalo (cm)
petal_length	Longitud del pétalo (cm)
petal_width	Ancho del pétalo (cm)

Conjunto de datos iris

Resultado de este paso: 150 semillas (una por cada flor).

2. Iteración para cada punto y_i :

Repetir:

a. Identificar todos los puntos vecinos x_j tales que

$$\|x_j - y_i^{(t)}\| \leq h$$

b. Calcular la **media ponderada** de los vecinos utilizando el kernel:

$$y_i^{(t+1)} = \frac{\sum_{j=1}^n K\left(\frac{\|y_i^{(t)} - x_j\|^2}{h^2}\right) x_j}{\sum_{j=1}^n K\left(\frac{\|y_i^{(t)} - x_j\|^2}{h^2}\right)}$$



c. Calcular el **vector de desplazamiento (mean shift)**:

$$m(y_i^{(t)}) = y_i^{(t+1)} - y_i^{(t)}$$

d. Verificar la convergencia:

Si $\|m(y_i^{(t)})\| < \varepsilon$, detener la iteración para este punto;

de lo contrario, actualizar $y_i^{(t)} = y_i^{(t+1)}$ y repetir.



a) Algoritmos

- Naive Search
- KD-Tree
- Ball Tree
- Grid-bases Search

Si el cambio es menor a un umbral ϵ , el punto deja de moverse: ya se considera convergido en el modo local de densidad. **Si no**, repite el ciclo con la nueva posición.

3. Obtención de modos:

Una vez que todos los puntos han convergido, almacenar los valores finales y_i como **modos candidatos**

“Una vez que todos los puntos han convergido, se almacenan los valores finales y_i como modos candidatos.”

1. Cada punto y_i tiene una posición final $y_i^{(\text{final})}$
2. Algunos de esos puntos se detendrán muy cerca unos de otros, porque subieron a la misma montaña (modo).
3. El algoritmo fusiona los puntos finales que están muy próximos (usando una tolerancia τ , por ejemplo $\tau = 0.1$).
4. Cada grupo de puntos fusionados define un clúster final.

4. Fusión de modos cercanos:

Si dos modos y_i y y_j satisfacen

$$\|y_i - y_j\| < \tau,$$

fusionarlos en un único centro de clúster.

1. Comparar todas las posiciones finales $y_i^{\{\text{final}\}}$. Se mide la distancia entre cada par de modos.
2. Definir un umbral de fusión τ (por ejemplo, $\tau = 0.1$). Si dos modos están más cerca que τ , se considera que son el mismo pico.
3. Fusionar esos modos: Se reemplazan por su promedio (o simplemente se elige uno como representante).
4. Asignar etiquetas finales: Cada punto del dataset queda asociado al modo (ya fusionado) al que llegó.

5. Asignación de clústeres:

Asignar cada punto original x_i al modo μ_j más cercano (el centro al que haya convergido).

1. Cada punto original x_i del dataset siguió una trayectoria durante el algoritmo, moviéndose en dirección de la densidad hasta llegar a un modo final.
2. Como sabemos qué modo alcanzó cada punto, simplemente:
 - Identificamos qué modo final (fusionado) le corresponde.
 - Se le asigna una etiqueta de clúster según ese modo.

MEAN-SHIFT

**MÉTODO NO SUPERVISADO DE CLUSTERING BASADO
EN DENSIDADES DE DATOS**

Presentan:

ANGEL LUIS VALDES SANCHEZ
BERNARDINO HERNÁNDEZ ROJAS